ノンパラメトリックカーネル密度推定

Li & Racine (2007, Sections 1.1 – 1.5)

松村 泰行（京都大学経済学研究科・博士後期課程１年）

最終更新: 2026 年 4 月 7 日

matsumura.yasuyuki.w85@kyoto-u.jp
https://yasu0704xx.github.io

参考文献

- Li & Racine (2007) Chapter 1
  - Chapter 1 のみ出版社のページから PDF をダウンロードできます。
  - Errata
  - Solutions Manual
  - R code
- 末石 (2015) 第 9 章
- 西山・人見 (2023) 第 1 章
- R パッケージ：`np`

目次（教科書：第 1.1 – 1.5 節）

ノンパラメトリック法とは何か？

カーネル密度推定量（１次元の場合）

漸近理論

バンド幅の選択

バイアスの処理

分布関数の推定

補遺：経験分布関数の統計的性質

補遺：漸近理論のための準備

ノンパラメトリック法とは何か？

ノンパラメトリックな問題とは何か？

- パラメトリックな問題
  - 推定対象を有限次元のパラメータで表現できる場合。
  - 例えば，線形回帰モデル $Y = \beta_1 X_1 + \beta_2 X_2 + \varepsilon$ を推定したいとする。
  - 推定する母数は $(\beta_1, \beta_2) \in \mathbb{R}^2$ なので，これはパラメトリックな問題である。

- ノンパラメトリックな問題
  - 推定対象を有限次元のパラメータで表現できない場合。
  - 例えば，モデル $Y = g(X) + \varepsilon$ を推定したいとする。
  - $g(\cdot)$ の関数形についての情報が何もないとする。
  - $g(\cdot)$ は無限次元の母数なので，これはノンパラメトリックな問題である。

- セミパラメトリックな問題
  - 有限次元の母数と無限次元の母数の組合せを推定する場合。
  - 興味のある部分のみパラメトリックに表現し，興味のない部分（局外パラメータ）はノンパラメトリックに表現することがある。

  - 部分線形回帰モデル (Robinson, 1988)

$$Y = \beta_1 X_1 + \beta_2 X_2 + g(Z) + \varepsilon$$

  - インデックスモデル (Ichimura, 1993; Hardle and Stoker, 1989, etc)

$$Y = g(\beta_1 X_1 + \beta_2 X_2) + \varepsilon$$

なぜノンパラメトリック法を用いるのか？

- 確率変数の分布や回帰関数の関数形などは，ノンパラメトリックな母数である。
  - 元来，そうである（はず）。

- ノンパラメトリックな母数に対して何か特定の分布や関数形を仮定することは，ややもすれば致命的な間違いの原因になり得る。
  - 誤差項は本当に正規分布にしたがっているのか？
  - 回帰関数は本当に（有限次元の母数に関して）線形なのか？

パラメトリック法とノンパラメトリック法のどちらを使うべきか？

- もし仮にパラメトリックな仮定が正しいのであれば，パラメトリックモデルを想定して母数を推定するのが効率性 (efficiency) の観点からは望ましいだろう。
- しかし，頑健性 (robustness) を考慮すると，パラメトリック法よりも弱い仮定で済むノンパラメトリック法が望ましい。

特定化の誤り

例 (Li and Racine, Example 1.1)

- 未知の確率変数 X の密度関数 $f(x)$ に興味があるとする。分析者は IID 標本 X_i $(i = 1, \cdots, n)$ を観測しているとする。
- モデル $X \sim \text{Normal}(\mu_0, \sigma_0^2)$ を仮定する。推定対象は $(\mu_0, \sigma_0^2) \in \mathbb{R}^2$ である。
- μ_0 の最尤推定量は標本平均 $\widehat{\mu} = \sum_{i=1}^n X_i/n$ であり，σ_0^2 の最尤推定量は標本分散 $\widehat{\sigma}^2 = \sum_{i=1}^n (X_i - \widehat{\mu})^2/n$ である。
- もし仮に正規分布の仮定が正しいならば，一般的な極値推定量の漸近理論から，$n \to \infty$ のとき，一致性

$$\widehat{\mu} \xrightarrow{p} \mu_0, \qquad \widehat{\sigma}^2 \xrightarrow{p} \sigma_0^2$$

が成り立つ。さらに，最尤推定量は漸近的に有効でもある。

- では，もし仮に $X \sim \text{Normal}(\mu, \sigma^2)$ というパラメトリックモデルの仮定が間違っていたらどうなるだろうか？
- 先ほどの MLE で考えていた尤度関数を $L(\mu, \sigma^2)$ と書くことにする。
- 特定化が誤っているので，$\widehat{\mu}$ や $\widehat{\sigma}^2$ は擬似最尤推定量 (QMLE)

$$\underset{(\mu,\sigma^2)}{\arg\max}\, L(\mu, \sigma^2)$$

であり，擬似真値 (pseudo-true value) [1] に対する一致性しか得られない。

$$\widehat{\mu} \xrightarrow{p} \mu_{\text{pseudo}}, \qquad \widehat{\sigma}^2 \xrightarrow{p} \sigma^2_{\text{pseudo}}$$

- 一般に $\mu_0 \neq \mu_{\text{pseudo}}$, $\sigma_0^2 \neq \sigma^2_{\text{pseudo}}$ なので，QMLE は漸近的にもバイアスを持つ。

[1] $\text{KLD}\left(f_0(x) || f(x;\theta)\right)$ を最小にする θ のこと。詳しくは Hansen (2022, Chapters 8 and 23) 等を参照。

代表的なノンパラメトリック法

局所的推定と呼ばれる方法

- カーネル推定（教科書 Chapters 1 – 6）
- k-nearest neighbor 推定（教科書 Chapter 14）

大域的推定と呼ばれる方法

- シリーズ推定（教科書 Chapter 15）

カーネル密度推定量（１次元の場合）

設定

- ある 1 次元の確率変数 $X \sim F(x)$ の IID 標本 X_i $(i = 1, \cdots, n)$ を観測している。
- $F(x)$ は連続（すなわち，滑らかな関数）であるとする。

- 分布関数 $F(x)$ に特定化の仮定を置かずに，密度関数 $f(x)$ を推定したい。
- つまり，密度関数 $f(x)$ をノンパラメトリックに推定したい。

ヒストグラム

- もっともシンプルな密度推定は，ヒストグラムを用いることである。
- 密度関数 $f(x)$ のサポートを J 個の幅 h の区間に分割したうえで，第 j 区間における推定量を $\widehat{f_j}(x) = n_j/nh$ （n_j は区間 j 内の観測値の個数）とすればよい。

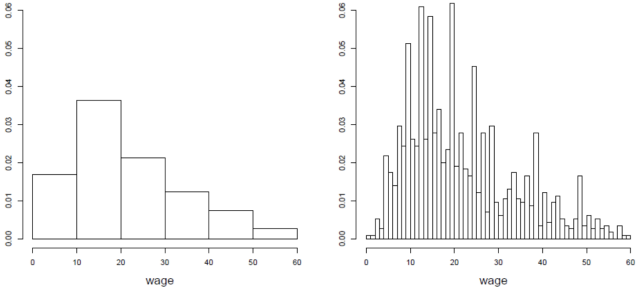

Figure 17.1: Histogram Estimate of Wage Density for Asian Women

Hansen (2022, Chapter 17)

- ヒストグラムは直観的で簡単である。

- しかし，問題もある。
- 3 変量以上のとき，図に描くのが困難である。
- 各区間の端点近傍でのパフォーマンスには疑問が残る。
- 幅 h の良い決め方は非自明である。
- 連続でない（微分できない）ので，漸近理論を考えるのが難しい。

ナイーブ推定量

- 確率変数 X の密度関数 (PDF) は

$$f(x) = \frac{d}{dx}F(x) = \frac{d}{dx}\Pr(X \leq x) \tag{1}$$

によって定義される。ただし，$F(x)$ は累積分布関数 (CDF) である。

- $F(x)$ に対する最も自然な推定量は，経験分布関数 (EDF) である：

$$\widehat{F}_n(x) = \frac{1}{n}\sum_{i=1}^{n}\mathbf{1}(X_i \leq x).$$

- 一般に，EDF は CDF の一致推定量であり，$\sqrt{n}$-consistency や漸近正規性を持つ。一様収束することと，そのオーダーも知られている。

- (1) に $\widehat{F}_n(x)$ を代入したいが，$\widehat{F}_n(x)$ は指示関数を含むため微分できない。

- かわりに，微分の定義

$$f(x) = \lim_{h \to 0} \frac{F(x+h) - F(x)}{h} = \lim_{h \to 0} \frac{F\left(x + \frac{h}{2}\right) - F\left(x - \frac{h}{2}\right)}{h}$$

にしたがって，次のような近似を考えてみる：

$$\begin{aligned}
\widehat{f}_{\text{naive}}(x) &= \frac{\widehat{F}_n\left(x + \frac{h}{2}\right) - \widehat{F}_n\left(x - \frac{h}{2}\right)}{h} \\
&= \frac{1}{nh} \sum_{i=1}^{n} \left[\mathbf{1}\left(X_i \leq x + \frac{h}{2}\right) - \mathbf{1}\left(X_i \leq x - \frac{h}{2}\right) \right] \\
&= \frac{1}{nh} \sum_{i=1}^{n} \mathbf{1}\left(x - \frac{h}{2} < X_i \leq x + \frac{h}{2}\right) = \frac{1}{nh} \sum_{i=1}^{n} \mathbf{1}\left(-\frac{1}{2} < \frac{X_i - x}{h} \leq \frac{1}{2}\right).
\end{aligned}$$

- $\widehat{f}_{\mathrm{naive}}(x)$ のことをナイーブ推定量[2] という。
- 標準正規分布の密度関数をナイーブ推定量 $(n = 100, h = 0.3)$ で推定した結果が，以下である（引用元：LN-1）。

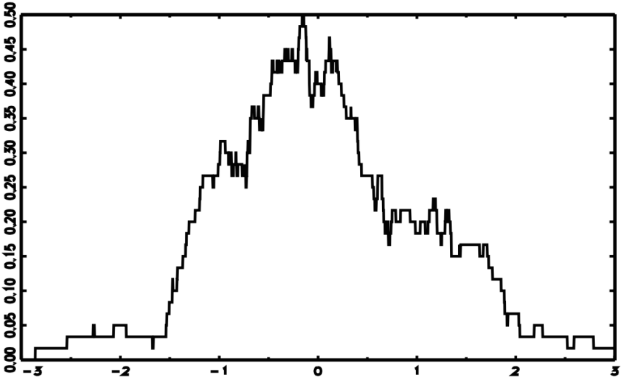

[2] Rosenblatt 推定量 (Rosenblatt, 1956) ともいう。

- ナイーブ推定量も指示関数を含むため，やはり微分できない。

- $k(v) = \mathbf{1}\left(-\frac{1}{2} < v \leq \frac{1}{2}\right)$ を用いて $\widehat{f}_{\mathrm{naive}}(x)$ を書き換えると，

$$\widehat{f}_{\mathrm{naive}}(x) = \frac{1}{nh}\sum_{i=1}^{n}\mathbf{1}\left(-\frac{1}{2} < \frac{X_i - x}{h} \leq \frac{1}{2}\right) = \frac{1}{nh}\sum_{i=1}^{n} k\left(\frac{X_i - x}{h}\right)$$

  となる。

- ナイーブ推定量を微分できないのは $k(v)$ が指示関数であることが原因なので，この $k(v)$ を滑らかな関数に取り換えてやるとうまくいくのではないだろうか？

カーネル密度推定量 (KDE)

- $k(v)$ が以下を満たしているとする：

$$\int_{-\infty}^{\infty} k(v)dz = 1. \tag{2}$$

- このような $k(v)$ を用いた密度関数 $f(x)$ に対する推定量

$$\widehat{f}(x) = \frac{1}{nh}\sum_{i=1}^{n} k\left(\frac{X_i - x}{h}\right) \tag{3}$$

のことをカーネル密度推定量 (KDE) という。

- $k(v)$ をカーネル関数という。(2) のとおり，カーネル自身も密度関数である。
- $h > 0$ をバンド幅（平滑化パラメータ）という。

代表的なカーネル関数

- ナイーブ推定量も KDE の一種である。ナイーブ推定量のカーネル $k(v) = \mathbf{1}\left(-\frac{1}{2} < v \leq \frac{1}{2}\right)$ は一様カーネルとか rectangular カーネルと呼ばれる。

- 他によく用いられているのは，例えば，以下の 3 つのカーネルである。

- Gaussian: $k(v) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}v^2\right)$
- Epanechnikov: $k(v) = \frac{3}{4\sqrt{5}}\left(1 - \frac{v^2}{5}\right)\mathbf{1}\left(|v| \leq \sqrt{5}\right)$
- Triangular: $k(v) = \frac{1}{\sqrt{6}}\left(1 - \frac{|v|}{\sqrt{6}}\right)\mathbf{1}\left(|v| \leq \sqrt{6}\right)$

- どのカーネルを用いても，推定結果が大きく変わるといったことはない。
- 漸近的にはどのカーネルを用いても収束のオーダーには影響しない。

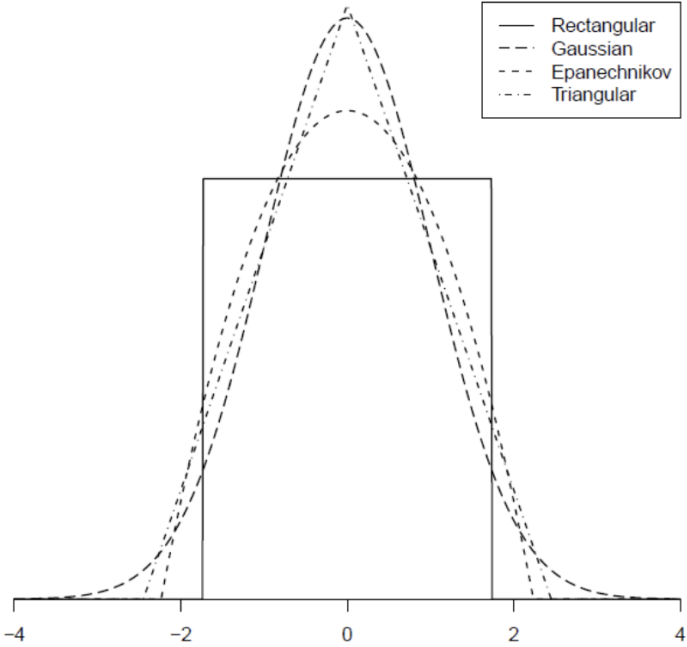
Rectangular
Gaussian
Epanechnikov
Triangular
−4
−2
0
2
4

バンド幅

- バンド幅を大きくとると，KDE はより滑らかになる。
  - 分散が抑えられるかわりに，バイアスが大きくなる。Oversmooth するという。
- バンド幅を小さくとると，KDE はより凸凹になる。
  - 分散は大きくなるが，バイアスを小さくできる。Undersmooth するという。

- このようなバンド幅を通じた bias-variance tradeoff は，平均二乗誤差 (MSE) がバイアス（の二乗）と分散に分解されることを確認すると理解しやすい。

- 後ほど，Li and Racine, Theorem 1.1 において考察する。

シミュレーション

設定

- データ： $X_1, \cdots, X_n \overset{\text{IID}}{\sim} \text{Normal}(0,1), \quad n \in \{500, 1000, 5000, 10000\}$
- バンド幅： MSE-optimal, MSE-optimal の半分, MSE-optimal の 2 倍
- カーネル： Epanechnikov

注意

- 今回は KDE のグラフを図示したいだけなので，繰り返し計算は 1 回だけ行った。
- 適切なバンド幅の選び方については後ほどきちんと考える。
- R のスクリプトはここからダウンロードできます。
- 必要に応じて `install.packages(c("np", "ggplot2"))` してください。

カーネル密度推定量

データ生成過程：標準正規分布，カーネル：Epanechnikov

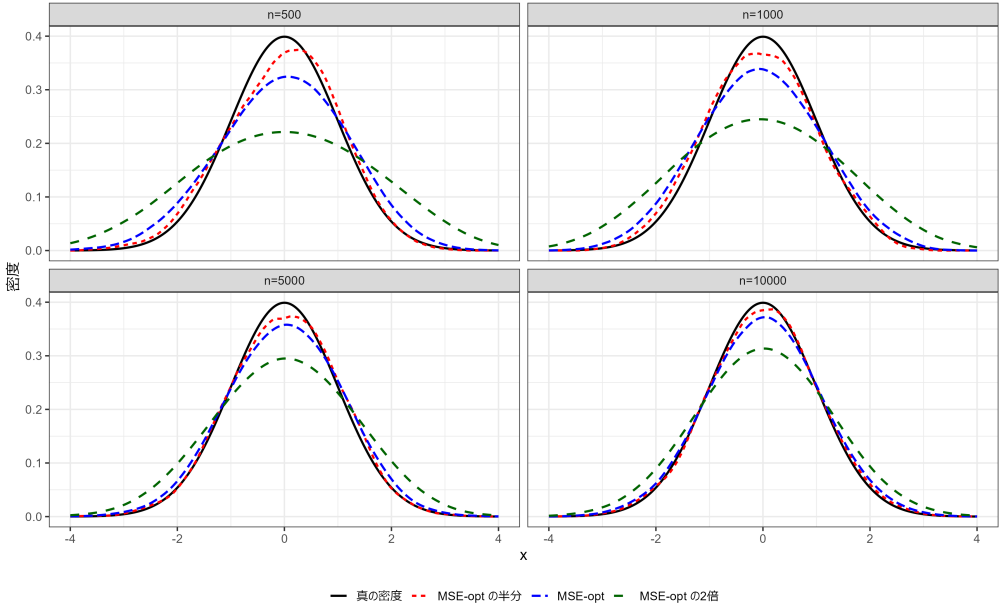

漸近理論

漸近理論

平均二乗収束

- $n \to \infty$ のとき， $h \to 0$ かつ $nh \to \infty$ ならば，
- $\mathrm{MSE}\left(\widehat{f}(x)\right) \to 0$ となる。よって，$\widehat{f}(x) \xrightarrow{p} f(x)$ となる。

一様収束

- $n \to \infty$ のとき， $nh^2 \to \infty$ ならば，
- $\sup_x |\widehat{f}(x) - f(x)| \xrightarrow{p} 0$ となる。

一様収束の速度

- バンド幅 $h > 0$ について，$h = C\left(\frac{\log\log n}{n}\right)^{\frac{1}{6}}$ であるとき，
- $\sup_x |\widehat{f}(x) - f(x)| = O\left(\left(\frac{\log\log n}{n}\right)^{\frac{1}{3}}\right)$ a.s. である。

漸近正規性

- $n \to \infty$ のとき， $h \to 0$ かつ $nh \to \infty$ かつ $nh^5 = O(1)$ ならば，
- $\sqrt{nh}\left(\widehat{f}(x) - f(x) - \frac{h^2}{2}f^{(2)}(x)\int v^2 k(v)dv\right) \xrightarrow{d}$ Normal $\left(0,\ f(x)\int k(v)^2 dv\right)$，
- もしくは，$\sqrt{nh}\left(\widehat{f}(x) - \mathbb{E}\left[\widehat{f}(x)\right]\right) \xrightarrow{d}$ Normal $\left(0,\ f(x)\int k(v)^2 dv\right)$ となる。
- $nh^5 = o(1)$ ならば $\sqrt{nh}\left(\widehat{f}(x) - f(x)\right) \xrightarrow{d}$ Normal $\left(0,\ f(x)\int k(v)^2 dv\right)$ となる。

平均二乗収束

Li and Racine: Theorem 1.1

$\{X_i\}_{i=1}^n$ を $X \sim f(x)$ からの IID 標本とする。$f(x)$ は 3 階連続微分可能で，各 $f^{(s)}(x)$ は一様に有界であるとする。x は X のサポートの内点であるとする。$\widehat{f}(x)$ は (3) で定義される KDE であるとする。ただし，カーネル関数 $k(v)$ は

$$\int k(v)dv = 1, \qquad k(v) = k(-v), \qquad \int v^2 k(v)dv = \kappa_2 < \infty. \tag{4}$$

を満たすとする。$n \to \infty$ のとき， $h \to 0$ かつ $nh \to \infty$ であるならば，

$$\mathrm{MSE}\left(\widehat{f}(x)\right) = \frac{h^4}{4}\left[\kappa_2 f^{(2)}(x)\right]^2 + \frac{\kappa f(x)}{nh} + o\left(h^4 + \frac{1}{nh}\right) = O\left(h^4 + \frac{1}{nh}\right)$$

となる。ただし，$\kappa = \int k^2(v)dv$ である。

証明の方針　平均二乗誤差をバイアスと分散に分解する。

- **バイアスの評価：** $\mathrm{bias}\left(\widehat{f}(x)\right) = \dfrac{h^2}{2}\kappa_2 f^{(2)}(x) + O(h^3)$
- **分散の評価：** $\mathrm{var}\left(\widehat{f}(x)\right) = \dfrac{1}{nh}\left\{\kappa f(x) + O(h)\right\}$

証明　平均二乗誤差は，

$$
\begin{aligned}
\mathrm{MSE}\left(\widehat{f}(x)\right) &= \mathbb{E}\left[\left(\widehat{f}(x) - f(x)\right)^2\right] = \mathbb{E}\left[\widehat{f}(x)^2\right] - 2f(x)\mathbb{E}\left[\widehat{f}(x)\right] + f(x)^2 \\
&= \mathbb{E}\left[\widehat{f}(x)^2\right] - \mathbb{E}\left[\widehat{f}(x)\right]^2 + \mathbb{E}\left[\widehat{f}(x)\right]^2 - 2f(x)\mathbb{E}\left[\widehat{f}(x)\right] + f(x)^2 \\
&= \left\{\mathbb{E}\left[\widehat{f}(x)^2\right] - \mathbb{E}\left[\widehat{f}(x)\right]^2\right\} + \left\{\mathbb{E}\left[\widehat{f}(x)\right] - f(x)\right\}^2 \\
&= \mathrm{var}\left(\widehat{f}(x)\right) + \mathrm{bias}\left(\widehat{f}(x)\right)^2
\end{aligned}
$$

のように，バイアス（の二乗）と分散の和に分解される。

まず，バイアスを評価しよう。バイアスの定義は

$$\mathrm{bias}\left(\widehat{f}(x)\right) \equiv \mathbb{E}\left[\widehat{f}(x)\right] - f(x) = \mathbb{E}\left[\frac{1}{nh}\sum_{i=1}^{n} k\left(\frac{X_i - x}{h}\right)\right] - f(x)$$

であるが，IID なので，

$$\mathrm{bias}\left(\widehat{f}(x)\right) = \frac{1}{h}\mathbb{E}\left[k\left(\frac{X_i - x}{h}\right)\right] - f(x)$$

と簡単にできる。期待値の定義より，

$$\mathrm{bias}\left(\widehat{f}(x)\right) = \frac{1}{h}\int k\left(\frac{z - x}{h}\right) f(z)dz - f(x)$$

である。変数変換 $v = \dfrac{z - x}{h}$ を行うと， $z = x + hv,\ dz = hdv$ に注意して，

$$\mathrm{bias}\left(\widehat{f}(x)\right) = \int k(v)f(x + hv)dv - f(x)$$

となる。

$f(x)$ は 3 階連続微分可能で，各 $f^{(s)}(x)$ は一様に有界 $(s = 0, 1, 2, 3)$ であると仮定していたので，$f(x + hv)$ に関して以下のテイラー展開が成り立つ。

$$\begin{aligned}
\mathrm{bias}\left(\widehat{f}(x)\right) &= \int k(v)\left\{f(x) + f^{(1)}(x)hv + \frac{h^2v^2}{2}f^{(2)}(x) + \frac{h^3v^3}{6}f^{(3)}(\tilde{x})\right\}dv - f(x) \\
&= f(x)\int k(v)dv + f^{(1)}(x)h\int vk(v)dv + \frac{h^2}{2}f^{(2)}(x)\int v^2k(v)dv + O(h^3) \\
&\quad - f(x)
\end{aligned}$$

カーネル $k(v)$ は (4) を満たすので（2 次カーネルなので），バイアスは

$$\mathrm{bias}\left(\widehat{f}(x)\right) = \frac{h^2}{2}f^{(2)}(x)\int v^2k(v)dv + o(h^2)$$

のように書くことができる。

次に，分散を評価しよう。

$$\mathrm{var}\left(\widehat{f}(x)\right) = \mathrm{var}\left[\frac{1}{nh}\sum_{i=1}^{n} k\left(\frac{X_i - x}{h}\right)\right] = \frac{1}{n^2h^2}\mathrm{var}\left[\sum_{i=1}^{n} k\left(\frac{X_i - x}{h}\right)\right]$$

IID なので，

$$\mathrm{var}\left(\widehat{f}(x)\right) = \frac{1}{nh^2}\mathrm{var}\left[k\left(\frac{X_i - x}{h}\right)\right]$$

である。分散は「二乗の期待値」と「期待値の二乗」の差なので，

$$\mathrm{var}\left(\widehat{f}(x)\right) = \frac{1}{nh^2}\left\{\mathbb{E}\left[k^2\left(\frac{X_i - x}{h}\right)\right] - \mathbb{E}\left[k\left(\frac{X_i - x}{h}\right)\right]^2\right\}$$

である。期待値の定義より，バイアスの計算と同様に積分の形でかける。

$$\mathrm{var}\left(\widehat{f}(x)\right) = \frac{1}{nh^2}\left\{\int k^2\left(\frac{z - x}{h}\right) f(z)dz - \left(\int k\left(\frac{z - x}{h}\right) f(z)dz\right)^2\right\}$$

変数変換 $v = \dfrac{z-x}{h}$ を行うと， $z = x + hv,\ dz = hdv$ に注意して，

$$
\begin{aligned}
\mathrm{var}\left(\widehat{f}(x)\right) &= \frac{1}{nh^2}\left\{\int k^2(v)f(x+hv)hdv - \left(\int k(v)f(x+hv)hdv\right)^2\right\} \\
&= \frac{1}{nh}\left\{\int k^2(v)f(x+hv)dv - h\left(\int k(v)f(x+hv)dv\right)^2\right\}
\end{aligned}
$$

となる。やはり，$f(x+hv)$ に関して以下のテイラー展開が成り立つ。

$$
\begin{aligned}
\mathrm{var}\left(\widehat{f}(x)\right) &= \frac{1}{nh}\left\{\int k^2(v)\left\{f(x) + f^{(1)}(\tilde{x})hv\right\}dv - h\left(f(x) + \mathrm{bias}\left(\widehat{f}(x)\right)\right)^2\right\} \\
&= \frac{1}{nh}\left\{f(x)\int k^2(v)dv + O(h)\right\} \\
&= \frac{1}{nh}\left\{\kappa f(x) + O(h)\right\}
\end{aligned}
$$

バイアスと分散のオーダーはそれぞれ，

$$\mathrm{bias}\left(\widehat{f}(x)\right) = \frac{h^2}{2} f^{(2)}(x) \int v^2 k(v) dv + o(h^2), \quad \mathrm{var}\left(\widehat{f}(x)\right) = \frac{1}{nh}\left\{\kappa f(x) + O(h)\right\}$$

であることが分かったので，平均二乗誤差は次のように評価される。

$$\mathrm{MSE}\left(\widehat{f}(x)\right) = \frac{h^4}{4}\left(\kappa_2 f^{(2)}(x)\right)^2 + \frac{\kappa f(x)}{nh} + o\left(h^4 + \frac{1}{nh}\right) = O\left(h^4 + \frac{1}{nh}\right)$$

$\square$

補足 (Li and Racine, Theorem 1.1)

- Thm 1.1 よりただちに，$\widehat{f}(x) - f(x) = O_p\left(h^2 + \frac{1}{\sqrt{nh}}\right) = o_p(1)$ も成り立つ。
  - ただし，X のサポートの内点における理論保証であることに注意が必要である。
  - 境界付近では「片側のみ」にしか観測値が存在しないため，バイアスを持つ。
  - 境界バイアスに対しては LPD (Cattaneo, Jansson and Ma, 2020) が有用である。
- 追加的に $f(x)$ が一様連続であることを仮定すると，

$$\sup_x \mathrm{MSE}\left(\widehat{f}(x)\right) \to 0$$

  も成り立つ。
- 一様確率収束 $\sup_x \left|\widehat{f}(x) - f(x)\right| \xrightarrow{p} 0$ を主張するためにはさらに強い条件 $(nh^2 \to \infty)$ が必要である。

IMSE-optimal なバンド幅

- Theorem 1.1 の結果より，$f(x)$ の一致推定のみが目的である場合は，バンド幅は，$n \to \infty$ のときに $h \to 0$ と $nh \to \infty$ を満たすように，

$$h = c \times n^{-\frac{1}{\alpha}} \quad \exists c > 0, \quad \exists \alpha > 1$$

のオーダーで選べばよい。c や α は，通常，Integrated MSE (IMSE, MISE)

$$\mathrm{IMSE}\left(\widehat{f}\right) \equiv \int \mathbb{E}\left[\widehat{f}(x) - f(x)\right]^2 dx = \frac{h^4 {\kappa_2}^2}{4} \int \left[f^{(2)}(x)\right]^2 dx \frac{\kappa}{nh} + o\left(h^4 + \frac{1}{nh}\right)$$

を最小化するようなバンド幅

$$h = c_0 \times n^{-\frac{1}{5}} \qquad c_0 = {\kappa_2}^{-\frac{2}{5}} \kappa^{\frac{1}{5}} \left(\int \left[f^{(2)}(x)\right]^2 dx\right)^{-\frac{1}{5}} (> 0)$$

を選択する。各点 x での pointwise な MSE ではなくて，X のサポート全体で MSE を最小化したいからである。

- c_0 は未知なので，何らかの方法で推定する必要がある（後ほど考える）。

一様収束

準備中

一様収束の速度

準備中

三角配列の中心極限定理 (Triangular Arrays CLT)

- 極値推定量の漸近正規性を証明する際には，Lindberg-Levy CLT を用いた。

Li and Racine: Lemma A.3

X_i $(i = 1, \cdots, n)$ が IID で，期待値 μ と分散 σ^2 が存在するとき，

$$\sqrt{n}\left(\frac{1}{n}\sum_{i=1}^{n} X_i - \mu\right) = \frac{1}{\sqrt{n}}\sum_{i=1}^{n}(X_i - \mu) \xrightarrow{d} \text{Normal}(0, \sigma^2)$$

が成り立つ。

- $\widehat{f}(x) = (nh)^{-1} \sum_{i=1}^{n} k\left(\frac{X_i - x}{h}\right)$ に関する漸近正規性を考える際には，
-
- Liapunov CLT（三角配列 triangular array の中心極限定理）
- Liapunov 条件

バンド幅の選択

IMSE-optimal なバンド幅

- IMSE-optimal なバンド幅は，

$$h = c_0 \times n^{-\frac{1}{5}} \qquad c_0 = {\kappa_2}^{-\frac{2}{5}} \kappa^{\frac{1}{5}} \left(\int \left[f^{(2)}(x) \right]^2 dx \right)^{-\frac{1}{5}}$$

をであるが，c_0 は未知なので，何らかの方法で推定する必要がある。

1. Plug-in 法
2. Silverman (1986) のバンド幅
3. Rule-of-Thumb
4. 最小二乗クロスバリデーション (LS-CV)
5. 最尤クロスバリデーション (Likelihood-CV)

Plug-in 法

準備中

Silverman (1986) のバンド幅

準備中

Rule-of-Thumb

準備中

最小二乗クロスバリデーション (LS-CV)

準備中

最尤クロスバリデーション (Likelihood-CV)

準備中

IMSE-optimal バンド幅は $oh^5 = o(1)$ を満たさない

- 漸近正規性の主張は，$nh^5 = O(1)$ のとき

$$\sqrt{nh}\left(\widehat{f}(x) - f(x) - \frac{h^2}{2} f^{(2)}(x) \int v^2 k(v) dv\right) \xrightarrow{d} \text{Normal}\left(0,\ f(x) \int k(v)^2 dv\right)$$

  でバイアスが残り，$nh^5 = o(1)$ のとき

$$\sqrt{nh}\left(\widehat{f}(x) - f(x)\right) \xrightarrow{d} \text{Normal}\left(0,\ f(x) \int k(v)^2 dv\right)$$

  でバイアスが消えるというものであった。
- IMSE-optimal なバンド幅は $h = O(n^{-1/5})$ なので，$nh^5 = O(1)$ である。
- つまり，IMSE-optimal なバンド幅を選択すると，中心化のために未知のバイアスを知ることが必要となってしまう。これは応用上の大きな問題である。

カーネル密度推定量

データ生成過程：標準正規分布，カーネル：Epanechnikov

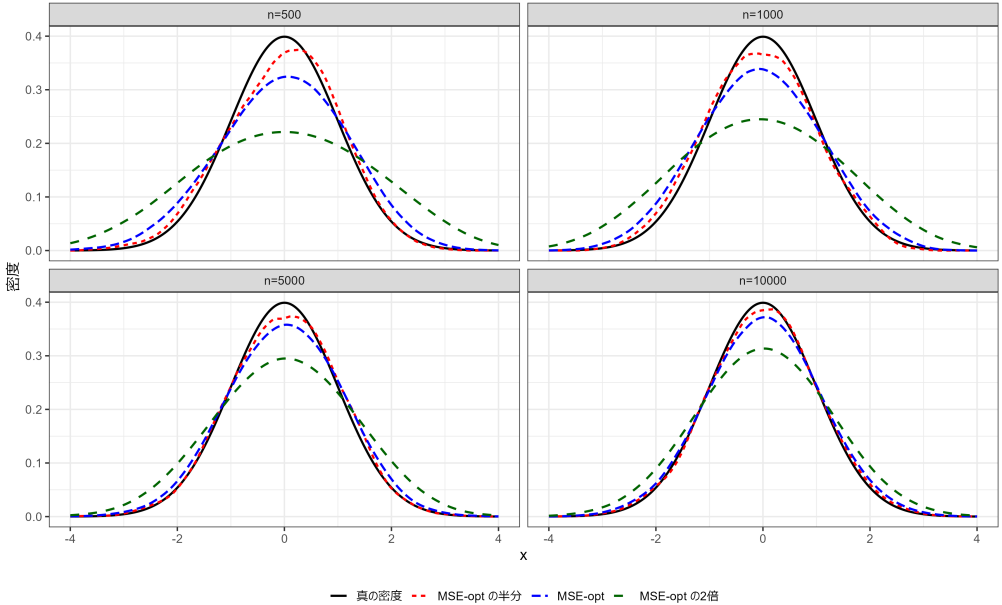

バイアスの処理

バイアスの処理

- 2 次カーネルと IMSE-optimal なバンド幅を選択すると，未知の漸近バイアスが残ってしまうことを確認した。
- 過小平滑化 (undersmoothing) でバイアスを消すことはできるが，分散が大きくなってしまうし，分析者の主観に依存するので，あまり良い方法とは言えない。

バイアスの軽減方法

1. 高次カーネルの利用 （教科書 Section 1.11）
2. 局所多項式密度推定 (LPD; Cattaneo, Jansson and Ma, 2020)

バイアスを補正する方法

1. ロバストバイアス補正 (RBC; Calonico, Cattaneo and Farrell, 2018)
2. ジャックナイフ法 (Schucany and Sommers, 1977)
3. 平滑化ブートストラップ

参考文献

- 西山 (2026) は，KDE のバイアス処理についてまとめた概説論文である。
- ブートストラップについては，西山・人見 (2023) の第 5 章が特に詳しい。

高次カーネル

- カーネル $k(v)$ が

$$\int k(v)dv = 1, \quad \int v^l k(v)dv = 0\,(l = 1, \cdots, j-1), \quad \int v^j k(v)dv = \kappa_j > 0$$

を満たすとき，$k(v)$ は j 次カーネルであるという。

- たとえば，(4) の条件を満たすカーネルは 2 次カーネルである。
- Li and Racine, Theorem 1.1 の証明を高次カーネルに拡張する。テイラー展開の次数を上げると，

$$\mathrm{bias}\left(\widehat{f}(x)\right) = \frac{h^j}{j!}\kappa_j f^{(j)}(x) + O(h^{j+1})$$

のように，バイアスのオーダーが $O(h^j)$ に改善される。

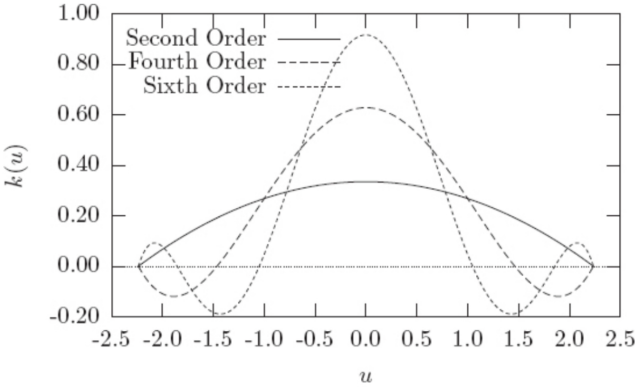

Figure 1.2: Epanechnikov kernels of varying order.

Li and Racine, Section 1.11

- 悪い面もある。
- 高次カーネルはサポート上で負になる部分があるため，推定値が負になり得る。
- すると，密度関数の推定量としての解釈が難しくなってしまう。

局所多項式密度推定 (LPD)

- Cattaneo, Jansson and Ma (2020) は，局所多項式密度推定 (LPD) によるバイアスの軽減を提案した。
- LPD のもとになっているアイデアは，カーネル法による回帰関数の推定方法のひとつである 局所多項式回帰 (LPR) にある。
- LPR については，例えば，Li and Racine, Section 2.5 を参照されたい。
- LPD が LPR から継承しているポイントは，Nadaraya-Watson 推定量ではなく LPR を用いることで特定のバイアスを軽減できる点である。

- 実は，Cattaneo, Jansson and Ma (2020) の方法は，不連続回帰デザイン (RDD) におけるプレテストでよく使われている。
- 川口・澤田 (2024) などの因果推論のテキストを参照されたい。
- Rパッケージ：`lpdensity`, `rddensity`

ロバストバイアス補正 (RBC)

- Calonico, Cattaneo and Farrell (2018) は，ロバストバイアス補正 (RBC) によるバイアスの補正を提案した。

ジャックナイフ法

- Schucany and Sommers (1977) は，ジャックナイフ法によるバイアスの補正を提案した。

平滑化ブートストラップ

準備中

分布関数の推定

KDE から分布関数を「復元」する

- 既に見たとおり，経験分布関数 (EDF) は分布関数 (CDF) の良い推定量である。
- しかし，EDF は滑らかではないので，応用上は不都合が生じるかもしれない。
- 滑らかな CDF の推定量が欲しい場合には，KDE を積分してはどうだろうか？

$$\widehat{F}_K(x) = \int_{-\infty}^{x} \widehat{f}(v)dv = \frac{1}{n}\sum_{i=1}^{n} G\left(\frac{x - X_i}{h}\right) \quad \text{with} \quad G(x) = \int_{-\infty}^{x} k(v)dv$$

- 1 次の漸近理論では，$\widehat{F}_K(x)$ は EDF と同じ漸近分布をもたらす。
- 一方で，$\widehat{F}_K(x)$ は高次の効率性の意味において EDF よりも優れている。
- これは，IMSE を考えるとわかりやすい。

MSE

Li and Racine: Theorem 1.2

a

Integrated MSE (IMSE)

準備中

IMSE-optimal なバンド幅

準備中

高次の効率性

準備中

補遺：経験分布関数の統計的性質

経験分布関数 (EDF) の性質

準備中

補遺：漸近理論のための準備

漸近理論の準備

西山・人見 (2023, Chapter 1)，清水 (2021, Chapter 4) 等が参考になる。